

บทที่ 7 · ระบบวางแผนการเรียน มทร.ธัญบุรี

RAG + LLM Engine

ระบบตอบคำถามเรื่องระเบียบและหลักสูตร
ที่ตอบจากเอกสารจริงเท่านั้น และบอกทุกครั้งว่าอ้างอิงจากไหน

เอกสาร 5 ฉบับ · 69 ส่วน

BM25 + TF-IDF + RRF

คำนวณตอบมั่ว 4 ชั้น

ทดสอบผ่าน 105 เคส

ทำไมต้องมีโมดูลนี้

นักศึกษามีคำถามเรื่องระเบียบตลอดเวลา แต่คำตอบกระจายอยู่ในเอกสารหลายฉบับที่ยาวและอ่านยาก

ถามคนไม่กัน

ช่วงลงทะเบียนมีคนถามพร้อมกันเป็นร้อย เจ้าหน้าที่กับอาจารย์ที่ปรึกษาตอบไม่ทัน

หาเองไม่เจอ

คำตอบอยู่ในข้อบังคับ ปฏิทินการศึกษา และโครงสร้างหลักสูตร คนละฉบับกัน ไม่รู้ว่าต้องเปิดเล่มไหน

ถาม AI กวไปแล้วมั่ว


โมเดลภาษาทั่วไปไม่รู้ระเบียบของ มทร.ธัญบุรี แต่ตอบเต็มปากเหมือนรู้จริง ซึ่งอันตรายกว่าไม่ตอบ

RAG คืออะไร อธิบายสั้นที่สุด

RAG = Retrieval-Augmented Generation — ค้นก่อน แล้วค่อยตอบ

LLM ธรรมดา

ตอบจากสิ่งที่จำมาตอนเทรน



ปัญหา: ตรวจสอบไม่ได้ว่าเอามาจากไหน
ไม่รู้ก็ยังตอบ และตอบผิดแบบมั่นใจ

ถาม “ถอนวิชาได้ถึงเมื่อไหร่”
อาจตอบระเบียบของมหาวิทยาลัยอื่น

RAG (ที่เราทำ)

ค้นเอกสารก่อน แล้วตอบจากสิ่งที่ค้นเจอ




ข้อดี: ตรวจสอบได้ว่าอ้างอิงจากเอกสารไหน
ไม่มีในเอกสาร = ไม่ตอบ

ตอบพร้อมแนบ “ข้อบังคับ หมวด 2 ข้อ 18”
ให้กดดูต้นทางได้ทุกคำตอบ

โครงสร้างภายในโมดูล 7

แบ่งเป็น 2 ช่วง — ช่วงเตรียมข้อมูล (ทำครั้งเดียวตอนเริ่ม) และช่วงตอบคำถาม (ทุกครั้งที่มีการถาม)

ช่วงเตรียมข้อมูล — ทำครั้งเดียวตอนระบบเริ่มทำงาน



ช่วงตอบคำถาม — ทุกครั้งที่มีการถาม




ถ้าคะแนนไม่ถึงเกณฑ์ หรือเป็นเรื่องที่คลังไม่มีข้อมูล → ตอบว่า “ไม่พบข้อมูล” แทน
ไม่เรียกโมเดลภาษาเลย จึงไม่มีทางแต่งคำตอบขึ้นมาเอง

มายด์แมปของโมดูล 7



ใครใช้โมดูลนี้ ทำอะไรได้บ้าง



ถาม 1 คำถาม เกิดอะไรขึ้นบ้าง

ตัวอย่าง: นักศึกษาถามว่า “ถอนรายวิชาได้ถึงเมื่อไหร่”

- 1

ดูก่อนว่าเป็นเรื่องที่เรามีข้อมูลไหม

ระบบมีรายการเรื่องที่เราว่าไม่มีข้อมูล เช่น ตารางสอน ค่าเทอมทุนการศึกษา ถ้าถามเรื่องพวกนี้จะตอบทันทีว่าไม่มี พร้อมบอกว่าไปถามที่ไหนได้
- 2

แปลงคำพูดชาวบ้านเป็นคำในเอกสาร

“ถอนรายวิชา” เติมคำว่า “สัญลักษณ์ W” และ “กำหนดเวลา” เข้าไปด้วย เพราะเอกสารราชการใช้คำเหล่านั้น ถ้าไม่แปลงจะค้นไม่เจอ
- 3

ค้นสองวิธีพร้อมกันแล้วรวมอันดับ

BM25 หาส่วนที่มีค่าตรงกัน · TF-IDF หาส่วนที่ความหมายใกล้เคียง · RRF รวมผลทั้งสอง — ส่วนที่ติดอันดับดีทั้งสองวิธีจะชนะ
- 4

เทียบคะแนนกับเกณฑ์

ได้ 0.3293 ซึ่งเกินเกณฑ์ 0.21 จึงตอบได้ — ถ้าถามเรื่องนอกหลักสูตรจะได้ราว 0.09 ซึ่งต่ำกว่าเกณฑ์ ระบบจะปฏิเสธการตอบ
- 5

ตอบพร้อมแหล่งอ้างอิง

ได้ “ข้อบังคับฯ — หมวด 2 การเพิ่ม-ถอนรายวิชา > ข้อ 18 กำหนดเวลาการเพิ่มและถอนรายวิชา” ผู้ใช้กดดูต้นทางได้ ถ้าใส่คีย์ Gemini ไว้ โมเดลจะเรียบเรียงให้อ่านง่ายขึ้นโดยห้ามเติมอะไรนอกเอกสาร

ด่านกันตอบมี 4 ชั้น

สิ่งที่ทำให้ระบบนี้ต่างจากแชทบอททั่วไป — ต้องผ่านครบทั้ง 4 ชั้นถึงจะได้คำตอบ

ชั้นที่ 1

รู้ขอบเขตตัวเอง

ประกาศไว้ล่วงหน้าว่าไม่มีข้อมูลเรื่องอะไรบ้าง ถ้ามมาตอบตรง ๆ ว่าไม่มี ไม่ยกเอกสารใกล้เคียงมาตอบแทน

ชั้นที่ 2

เกณฑ์คะแนน

คะแนนค้นคืนต่ำกว่า 0.21 ถือว่าไม่เกี่ยวข้อง ตอบว่าไม่พบข้อมูลโดยไม่เรียกโมเดลภาษาเลย

ชั้นที่ 3

สั่งกำกับโมเดล

คำสั่งบังคับให้ตอบจากเอกสารที่ให้ไปเท่านั้น ห้ามเติมจากความรู้ทั่วไป และต้องอ้างอิงหมายเลขเอกสาร

ชั้นที่ 4

แบบต้นทางเสมอ

คืนรายการเอกสารที่ใช้สร้างคำตอบจริง ไม่ใช่ผลค้นทั้งหมด ผู้ใช้ตรวจสอบได้ทุกคำตอบ

หลักคิด ระบบที่ยอมบอกว่า “ไม่รู้” เชื่อถือได้มากกว่าระบบที่ตอบทุกคำถาม

วัดผลอย่างไร

ใช้ชุดคำถามมาตรฐาน (golden set) แบ่งเป็นสองฝั่ง ต้องผ่านทั้งสองฝั่งถึงจะถือว่าระบบยังทำงานถูก

105

เทสอัตโนมัติผ่านทั้งหมด

14/14

ชุดคำถามมาตรฐาน

69

ส่วนเอกสารในคลัง

0.21

เกณฑ์ตัดสินใจ

คำถาม	ประเภท	คะแนน	ผล
ได้ F ต้องทำยังไง	ต้องตอบได้	0.5387	ผ่าน เจอข้อบังคับ หมวด 3 ข้อ 23 การเรียนซ้ำ
เรียนเกินกี่ปีจะถูกปรับ	ต้องตอบได้	0.4934	ผ่าน เจอคำถามที่พบบ่อย
ถอนรายวิชาได้ถึงเมื่อไหร่	ต้องตอบได้	0.3293	ผ่าน เจอข้อบังคับ หมวด 2 ข้อ 18
แนะนำร้านกาแฟหน่อย	ต้องไม่ตอบ	0.0899	ผ่าน ต่ำกว่าเกณฑ์ จึงปฏิเสธ
ราคาข้าวมันไก่เท่าไร	ต้องไม่ตอบ	0.0691	ผ่าน ต่ำกว่าเกณฑ์ จึงปฏิเสธ

ทำไมเลือกแบบนี้

เรื่อง	ทางเลือกทั่วไป	ที่เราเลือก	เหตุผล
ตัดคำไทย	pythainlp	character n-gram (3,4)	pythainlp หนัก 250 MB ต้องโหลด dictionary — วัดจริงแล้ว n-gram (3,4) แยกคำถามในเรื่องกับนอกเรื่องได้ห่างที่สุด
ฐานข้อมูลเวกเตอร์	Qdrant + embedding	TF-IDF ในหน่วยความจำ	คลังมีแค่ 69 ส่วน ค้นในหน่วยความจำเร็วพอและไม่ต้องรันบริการเพิ่ม · แยกคลาสไว้แล้ว เปลี่ยนภายหลังได้ทันที
รวมผลค้นสองวิธี	ถ่วงน้ำหนักคะแนนดิบ	Reciprocal Rank Fusion	คะแนนของ BM25 กับ TF-IDF คนละสเกล เอามาบวกกันตรง ๆ ไม่ได้ · RRF ใช้ “อันดับ” จึงเทียบกันได้
ถ่วงน้ำหนักรหัสวิชา	บวกคะแนนคงที่	คูณคะแนน	การบวกดันส่วนที่ไม่เกี่ยวข้องข้ามเกณฑ์ได้ · การคูณขยายเฉพาะส่วนที่เกี่ยวข้องอยู่แล้ว
โมเดลภาษา	บังคับต้องมี API key	ไม่มีคีย์ก็ทำงานได้	ไม่มีคีย์ = ยกข้อความจากเอกสารมาแสดงตรง ๆ ซึ่ง “ไม่มีทางมั่ว” · มีคีย์ = เรียบเรียงให้อ่านง่ายขึ้น

โมดูล 7 ส่งมอบอะไร

6 endpoint พร้อมใช้

/generate ตอบคำถาม · /knowledge/search ค้นเอกสาร · /explain/plan อธิบายแผนการเรียนรู้ · /ingest เพิ่มเอกสาร

เครื่องมือโมดูลอื่นยกไปใช้ได้

โมดูล 09 พอร์ตตัวค้นคืนทั้งชุดไปรันในเบราว์เซอร์ ได้คะแนนตรงกับฝั่ง Python ทุกตำแหน่งทดสอบ

วิธีวัดคุณภาพที่ทำซ้ำได้

ชุดคำถามมาตรฐานรันได้ทั้งใน CI และกดรันดูสด ๆ บนหน้าเว็บ ไม่ต้องเชื่อบอกเล่า

ข้อจำกัดที่ต้องบอกให้ชัด เอกสารทั้ง 5 ฉบับเป็นข้อมูลจำลองสำหรับต้นแบบ ต้องแทนที่ด้วยฉบับจริงจากมหาวิทยาลัยก่อนนำไปใช้จริง ตัวระบบไม่ต้องแก้ แค่เปลี่ยนไฟล์ในคลังแล้วสร้างดัชนีใหม่